

Documentação - Tratamento de Dados com Pandas

Este documento descreve o processo de tratamento de dados realizado utilizando a linguagem Python e a biblioteca Pandas. O objetivo é preparar um conjunto de dados para futuras análises e mineração de dados.

1. Importação das bibliotecas pandas e numpy.
2. Leitura do arquivo CSV contendo os dados originais.
3. Verificação das informações gerais do DataFrame com `info()`, `head()` e `tail()`.
4. Criação de uma cópia do DataFrame original para preservar os dados crus.
5. Substituição de valores nulos na coluna 'Calories' por 0.
6. Substituição de valores nulos na coluna 'Date' por '1900/01/01'.
7. Substituição do valor '1900/01/01' por NaN na coluna 'Date'.
8. Conversão da coluna 'Date' para o tipo datetime.
9. Correção do valor '20201226' para o formato datetime correspondente.
10. Conversão completa da coluna 'Date' utilizando `pd.to_datetime` com erro coercivo.
11. Remoção de registros com valores nulos na coluna 'Date'.
12. Impressão do DataFrame final com os dados tratados.

Código Fonte:

```
import pandas as pd
import numpy as np

df_original = pd.read_csv("dados.csv")

print("Informações gerais sobre o conjunto de dados:")
print(df_original.info())
print("\nPrimeiras 5 linhas:")
print(df_original.head())
print("\nÚltimas 5 linhas:")
print(df_original.tail())

df = df_original.copy()

df['Calories'].fillna(0, inplace=True)
print("\nApós substituição de nulos em 'Calories':")
print(df)

df['Date'].fillna('1900/01/01', inplace=True)
print("\nApós substituição de nulos em 'Date' por '1900/01/01':")
print(df)
```

```
df['Date'].replace('1900/01/01', np.nan, inplace=True)

try:
    df['Date'] = pd.to_datetime(df['Date'], format='%Y/%m/%d')
except Exception as e:
    print("\nErro encontrado na conversão de datas:", e)

df['Date'] = df['Date'].replace('20201226', pd.to_datetime('2020-12-26'))

df['Date'] = pd.to_datetime(df['Date'], errors='coerce')

print("\nApós tratamento completo da coluna 'Date':")
print(df)

df.dropna(subset=['Date'], inplace=True)

print("\nDataFrame final após remoção de nulos:")
print(df)
```